


一、监督学习完整流程（房价预测为例）

Housing Prices (Portland, OR)



给出正确答案，根据我们的数据来说房子实际的价格是多少（回归问题-根据之前的数据预测出一个准确的输出值）

另一种监督学习流程-分类问题（寻找癌症肿瘤问题）

当我们想要预测离散的输出值，例如寻找癌症肿瘤并想要确认肿瘤是良性的还是恶性的，这就是 0/1 离散输出问题。

在监督学习中我们有一个数据集（训练集，包含不同房屋价格），我们的任务就说从这个数据中学习预测房屋的价格。

Training set of housing prices (Portland, OR)

Size in feet ² (x)	Price (\$) in 1000's (y)
2104	460
1416	232
1534	315
852	178
...	...

常见的符号定义

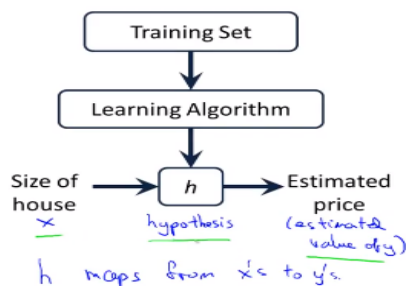
Notation:

- m = Number of training examples
- x 's = "input" variable / features
- y 's = "output" variable / "target" variable

注意： m 代表训练样本的数量, (x, y) — x 作为训练样本， y 作为输出数据（结果）

$(x(i), y(i))$ i 上标， i 代表训练行

监督学习算法工作方式：



注：讲训练集里的房屋价格，放到学习算法中，然后输出一个函数，通常大小写成 h (h 代表 hypothesis(假设) h 表示一个函数)

输入的是房屋尺寸大小，就像想出售的房屋； h 根据输入的 x 值来得出 y 值


二、代价函数（最有可能的直线与我们的数据相拟合）


Training Set	Size in feet ² (x)	Price (\$) in 1000's (y)
	2104	460
	1416	232
	1534	315
	852	178

$m = 47$

Hypothesis: $h_{\theta}(x) = \theta_0 + \theta_1 x$

通过 m （训练数据集），假设函数用来进行预测的函数就是这样是线性函数形式。引入术语 θ_0, θ_1 （模型参数），主要讨论如何选择不同参数 θ_0 和 θ_1 ，我们会得到不同的假设函数，如下三组例子所示





Idea: Choose θ_0, θ_1 so that $h_\theta(x)$ is close to y for our training examples (x, y)

x, y

假设 θ_0 和 θ_1 是直线，得出这两个参数的值来假设函数表示的直线，尽量与这些数据点有很好的拟合。在我们训练集中我们会得到一定数量的样本， x 表示卖出哪所房子，并且知道这所房子的实际价格，所以我们尽量选择参数值，给出训练集中的 x 值，我们能合理的预测值，让我们给出标准的定义在线性回归中，我们要解决的是一个最小化问题。

$$\text{minimize}_{\theta_0, \theta_1} \frac{1}{n} \sum_{i=1}^n (h_\theta(x^{(i)}) - y^{(i)})^2$$

#training examples

实现预测值与实际值之差平方值最小，尽量减少平均误差。
首先要定义一个代价函数

$$J(\theta_0, \theta_1) = \frac{1}{2n} \sum_{i=1}^n (h_\theta(x^{(i)}) - y^{(i)})^2$$

我们主要做的是关于 θ_0 和 θ_1 对函数 $J(\theta_0, \theta_1)$ 求最小值

$$J(\theta_0, \theta_1) = \frac{1}{2n} \sum_{i=1}^n (h_\theta(x^{(i)}) - y^{(i)})^2$$

minimize $J(\theta_0, \theta_1)$
 θ_0, θ_1 Cost function

代价函数如上图所示，代价函数也被称为平方误差函数，如下图所示：

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 = \frac{1}{2m} \sum_{i=1}^m (h_\theta(x_i) - y_i)^2$$

代价函数可视化

使用一个简化假设也就是 $\theta_1 \cdot x$ 我们可以将这个函数看成是把 θ_0 设为 0，所以只有一个参数就是 θ_1 代价函数看起来与之前的很像唯一的区别是现在 $h(x)$ 等于 $\theta_1 \cdot x$ 只有一个参数 θ_1 所以我的优化目标是将 $J(\theta_1)$ 最小化。用图形表示是过原点的直线。

Hypothesis:

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

Parameters:

$$\theta_0, \theta_1$$



Cost Function:

$$\rightarrow J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Goal: minimize $J(\theta_0, \theta_1)$

$$h_{\theta}(x) = \theta_1 x$$

$$\theta_0 = 0$$


$$\theta_1$$



$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$


minimize $J(\theta_1)$

需要理解两个重要函数：第一个是假设函数。第二个是代价函数
假设函数：



$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$= \frac{1}{2m} \sum_{i=1}^m (\theta_1 x^{(i)} - y^{(i)})^2 = \frac{1}{2m} (0^2 + 0^2 + 0^2) = 0$$





$$\theta_1 = 0.5?$$

$$\theta_1$$

$$J(1) = 0$$

代价函数：



最终目标: we should try to minimize the cost function. In this case, $\theta_1 = 1$ is our global minimum

深度学习代价函数的作用

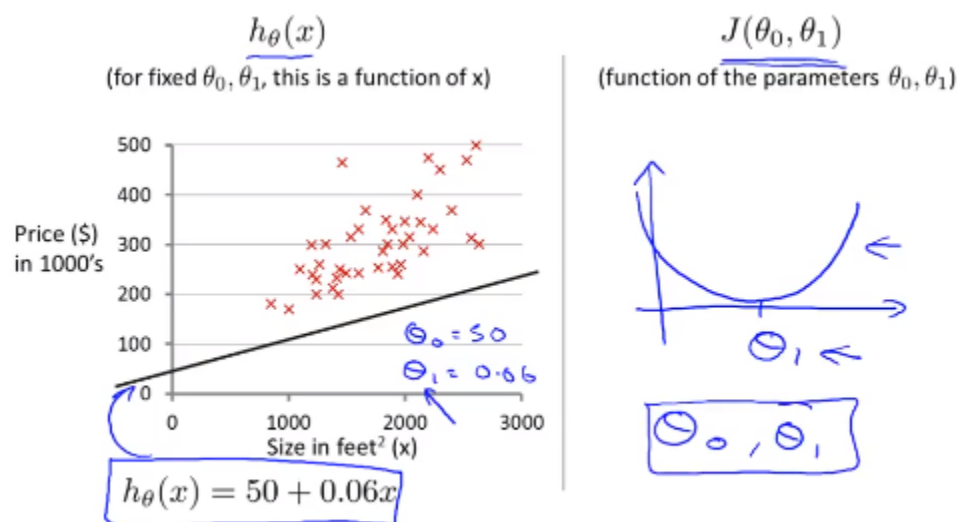
几个重要公式包括了假设 h 、参数 θ 、代价函数 J 以及优化目标

Hypothesis: $h_{\theta}(x) = \theta_0 + \theta_1 x$


Parameters: θ_0, θ_1

Cost Function: $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

Goal: minimize $J(\theta_0, \theta_1)$

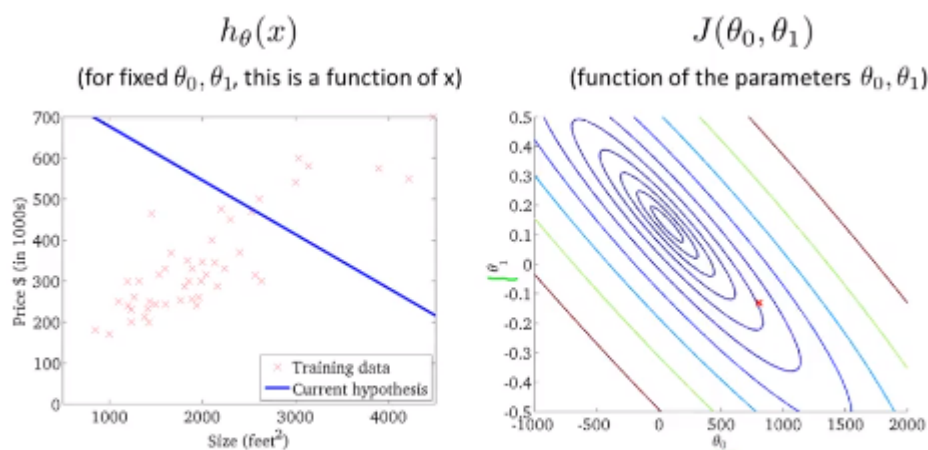


仍然呈现类似的某种弓形 实际上这取决于训练样本



随着你改变 θ_0 和 θ_1 的大小 你便会得到不同的代价函数

竖直方向 的高度就表示代价函数 $J(\theta_0, \theta_1)$ 的值 不难发现这是一个弓形曲面 我们来看看三维图 这是这个曲面的三维图 水平轴是 θ_0, θ_1 竖直方向表示 $J(\theta_0, \theta_1)$ 旋转一下这个图 就更能理解这个弓形曲面所表示的代价函数了。



误差平方通过这些图形，更接近代价函数这些值。